TEK-UP

Séries Temporelles pour Data Science & IA

Mini-projet

Le prix du Bitcoin est-il prévisible à court terme ?

Bitcoin et Ethereum, données journalières Yahoo Finance (2018-2026)

Réalisé par : Syrine Bejaoui Saif Sbaiti
Maryem Jbeli Yosri Karchoud

Encadré par : Mrs. Ahmed DHOUIBI

12 Octobre 2026

1. Introduction **3**
2. Données et préparation **3**
Figure 1 — Prix du Bitcoin et de l'Ethereum (échelle log) et moyenne mobile 30 jours 4
3. Analyse exploratoire **4**
Tableau 1 — Statistiques des rendements journaliers (apprentissage) 4
Tableau 2 — Tests de stationnarité 5
4. Modélisation classique **6**
4.1 ARIMA **6**
Tableau 3 — Modèles ARIMA retenus par chaque méthode 6
4.2 VAR, Granger et cointégration **7**
Tableau 4 — Causalité de Granger et cointégration 7
4.3 GARCH **8**
Tableau 5 — Comparaison des modèles de volatilité 8
5. Modélisation avancée (Python) **9**
6. Prévision et évaluation **10**
Tableau 6 — Erreurs sur le test (317 prévisions par horizon) 10
Figure 7 — Prévisions à 1 jour (haut) et écart cumulé d'erreur par rapport au naïf (bas) 11
Tableau 7 — Comparaison des modèles 11
7. Extension : corrélation glissante (Python) **12**
Figure 8 — Corrélation glissante sur 90 jours et volatilité réalisée du Bitcoin 12
8. Utilisation d'un LLM **12**
Prompt 1 — hypothèses de modèles **13**
Prompt 2 — explication pour un décideur **13**
Prompt 3 — recommandations simulées **13**
Bilan 13
9. Discussion critique **14**
Limites des modèles **14**
IA générative et séries temporelles financières **14**
10. Conclusion **15**
Annexe A — Environnement **16**
Figure 9 — Bibliothèques et version utilisées 16
Annexe B — Prompts **16**
Figure 10 — Prompt 1 16
Figure 11 — Prompt 2 17
Figure 12 — Prompt 3 17
Annexe C — Résultats en R **17**
Figure 13 — Sélection du modèle ARIMA 18
Figure 14 —Résultats du test de cointégration de Johansen 18
Figure 15 —Estimation du modèle GARCH retenu 19
Figure 16 —Comparaison des performances de prévision 19

1. Introduction

Pour ce projet nous avons choisi la thématique finance, avec deux cryptomonnaies : le Bitcoin (BTC-USD) et l'Ethereum (ETH-USD). Ce choix s'explique par le fait que ce sont deux actifs très corrélés, très volatils et cotés tous les jours, ce qui permet d'appliquer à la fois les modèles multivariés (VAR, cointégration) et les modèles de volatilité (GARCH).

La question posée est : **peut-on prévoir le prix du Bitcoin à 1, 5 et 10 jours, et est-ce que l'Ethereum aide à mieux le prévoir ?** Chaque modèle est comparé à une référence simple, la prévision naïve, qui dit que le prix de demain sera celui d'aujourd'hui.

Le code est fourni en Python (notebook, sections 1 à 7) et en R (fichier Rmd, socle classique). Les réseaux de neurones et l'extension sont faits en Python uniquement. Les chiffres du rapport viennent du notebook Python.

2. Données et préparation

Les données sont téléchargées depuis Yahoo Finance par le code (yfinance en Python, quantmod en R), en journalier, du 1er janvier 2018 au 30 septembre 2026. Il n'y a aucun jour manquant puisque le marché crypto est ouvert 7 jours sur 7, et Adj Close est égal à Close car une crypto ne verse pas de dividende.

On a construit le log-prix, le rendement logarithmique (différence du log-prix), une moyenne mobile sur 30 jours et la volatilité réalisée sur 30 jours. Après la suppression des 30 premiers jours (indicateurs non définis), on a 3 165 observations. Le découpage est chronologique : 2 848 jours pour l'apprentissage (jusqu'au 17/11/2025) et 317 jours pour le test (jusqu'au 30/09/2026). On n'utilise jamais le test pour estimer quoi que ce soit.

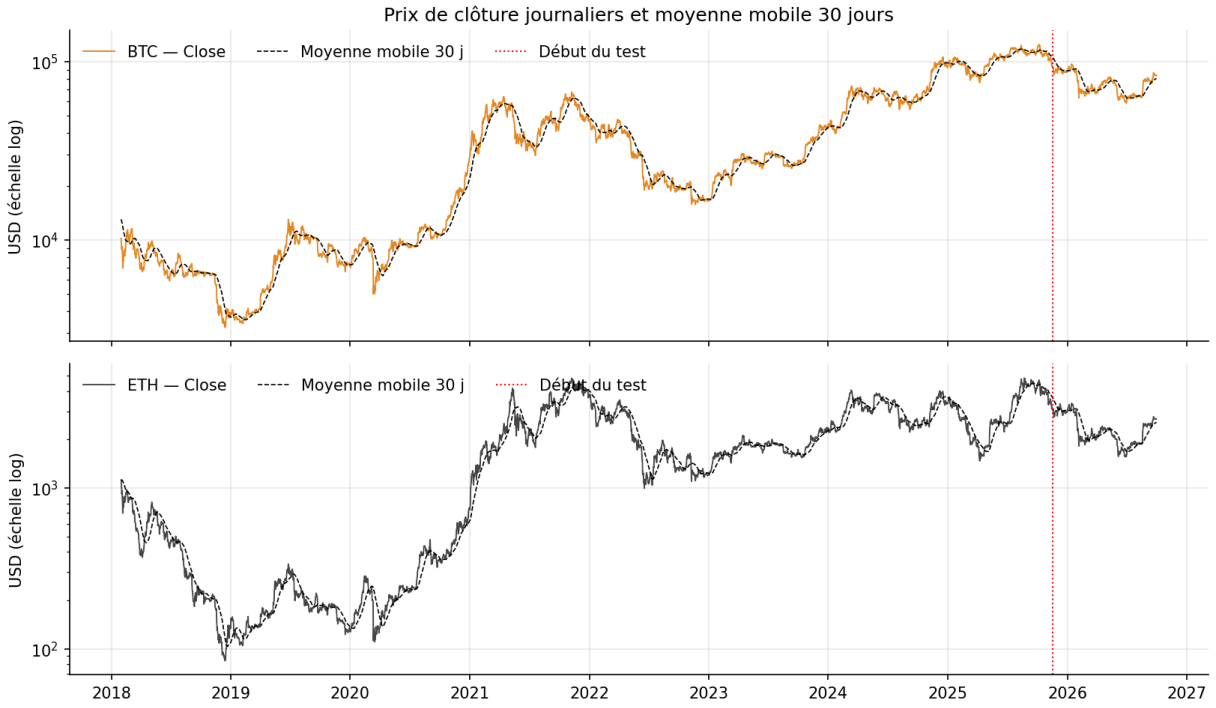


Figure 1 — Prix du Bitcoin et de l'Ethereum (échelle log) et moyenne mobile 30 jours

3. Analyse exploratoire

La figure 1 montre une tendance qui change plusieurs fois de sens (hausse en 2020-2021 et 2023-2025, baisse en 2018 et 2022) et des ruptures brutales, comme mars 2020. Les deux séries ont des profils très proches.

Tableau 1 — Statistiques des rendements journaliers (apprentissage)

	Moyenne	Écart-type	Min	Max	Skewness	Kurtosis (excès)
Rendement BTC	0,078 %	3,39 %	−46,5 %	17,2 %	−0,95	15,3
Rendement ETH	0,036 %	4,47 %	−55,1 %	23,1 %	−0,89	11,4

La moyenne est très petite devant l'écart-type, donc le signal est faible. Le kurtosis élevé montre des queues épaisses (beaucoup d'événements extrêmes) et le skewness négatif indique que les grosses baisses sont plus fréquentes que les grosses hausses. La corrélation entre les deux rendements est de 0,83.

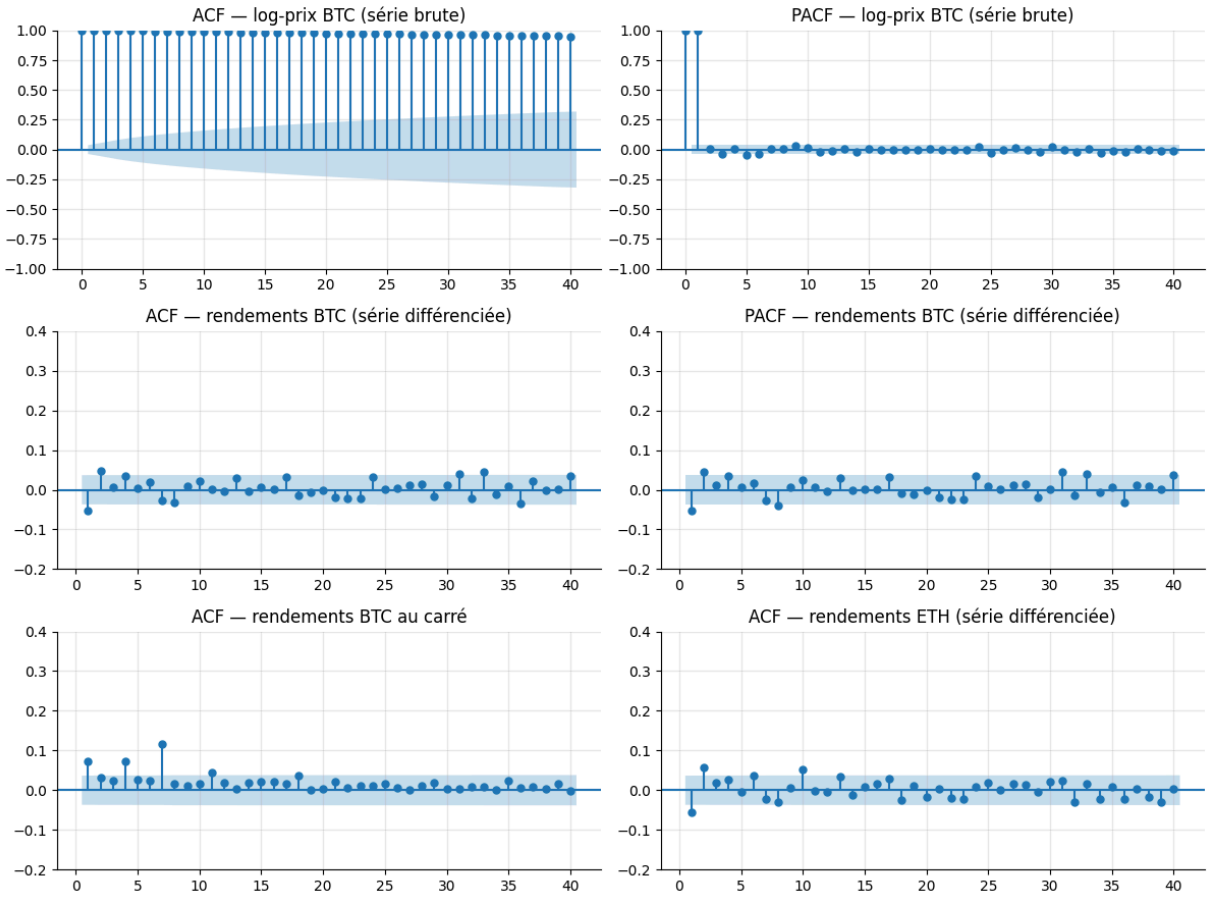


Figure 2 — ACF et PACF du log-prix, des rendements et des rendements au carré

L'ACF du log-prix reste proche de 1 sur tous les retards, ce qui est typique d'une série non stationnaire. Sur les rendements, presque tous les retards sont dans la bande de confiance (seulement les retards 1 et 2, autour de −0,05), donc il y a très peu de mémoire. Par contre les rendements au carré ont plusieurs retards significatifs : l'ampleur des variations dépend du passé, ce qui annonce un effet ARCH.

La décomposition STL (période 7) donne une force de tendance de 0,998 et une force de saisonnalité nulle. Le test de Kruskal-Wallis sur les rendements par jour de la semaine donne p = 0,34, donc pas d'effet jour. On n'a pas de saisonnalité à modéliser.

Pour les valeurs aberrantes, on a utilisé un score z robuste (médiane et MAD sur les 90 jours précédents). On trouve 44 jours au-dessus du seuil de 5 (1,4 %), le pire étant le 12 mars 2020 (krach COVID). On les a gardés car ce sont de vrais événements de marché et non des erreurs.

Tableau 2 — Tests de stationnarité

Série	ADF p-value	KPSS p-value	Conclusion
Log-prix BTC	0,529	≤ 0,01	Non stationnaire
Rendement BTC	< 0,001	≥ 0,10	Stationnaire

Série	ADF p-value	KPSS p-value	Conclusion
Log-prix ETH	0,408	≤ 0,01	Non stationnaire
Rendement ETH	< 0,001	≥ 0,10	Stationnaire

On a utilisé les deux tests car ils ont des hypothèses nulles opposées (racine unitaire pour l'ADF, stationnarité pour le KPSS). Ils sont d'accord dans les quatre cas : les log-prix sont I(1) et on différencie une fois (d = 1).

4. Modélisation classique

Tous les modèles suivent le même protocole : les paramètres sont estimés sur l'apprentissage puis gardés fixes, et on fait une prévision glissante sur les 317 jours de test (à chaque date on prévoit les 10 jours suivants avec l'information disponible). On évalue à 1, 5 et 10 jours.

4.1 ARIMA

Vu l'ACF/PACF, on a d'abord testé des petits modèles à la main, puis une recherche automatique sur p, q ≤ 3 (avec et sans dérive) et pmdarima.

Tableau 3 — Modèles ARIMA retenus par chaque méthode

Méthode	Modèle	AIC	BIC
Manuelle	ARIMA(1,1,1)	−11 190,4	−11 172,5
Recherche exhaustive (AIC)	ARIMA(2,1,0)	−11 192,1	−11 174,3
pmdarima	ARIMA(0,1,2)	−11 191,9	−11 174,0
Recherche exhaustive (BIC)	ARIMA(0,1,0)	−11 183,0	−11 177,0

Les trois premiers modèles sont à moins de 2 points d'AIC, donc équivalents. On garde l'**ARIMA(2,1,0)** (meilleur AIC), avec des coefficients de −0,050 et 0,045. Le BIC préfère la marche aléatoire ARIMA(0,1,0), ce qui montre qu'il y a très peu de chose à modéliser. Le SARIMA avec une saisonnalité de 7 jours dégrade l'AIC et le BIC, on ne l'a donc pas gardé.

Diagnostic des résidus : le test de Ljung-Box ne rejette pas l'indépendance (p = 0,13). Par contre Jarque-Bera rejette la normalité (kurtosis de 18) et le test ARCH-LM rejette l'homoscédasticité ($p \approx 3 \times 10^{-8}$). Le modèle est correct pour la moyenne mais la variance n'est pas constante, d'où le GARCH en section 4.3.

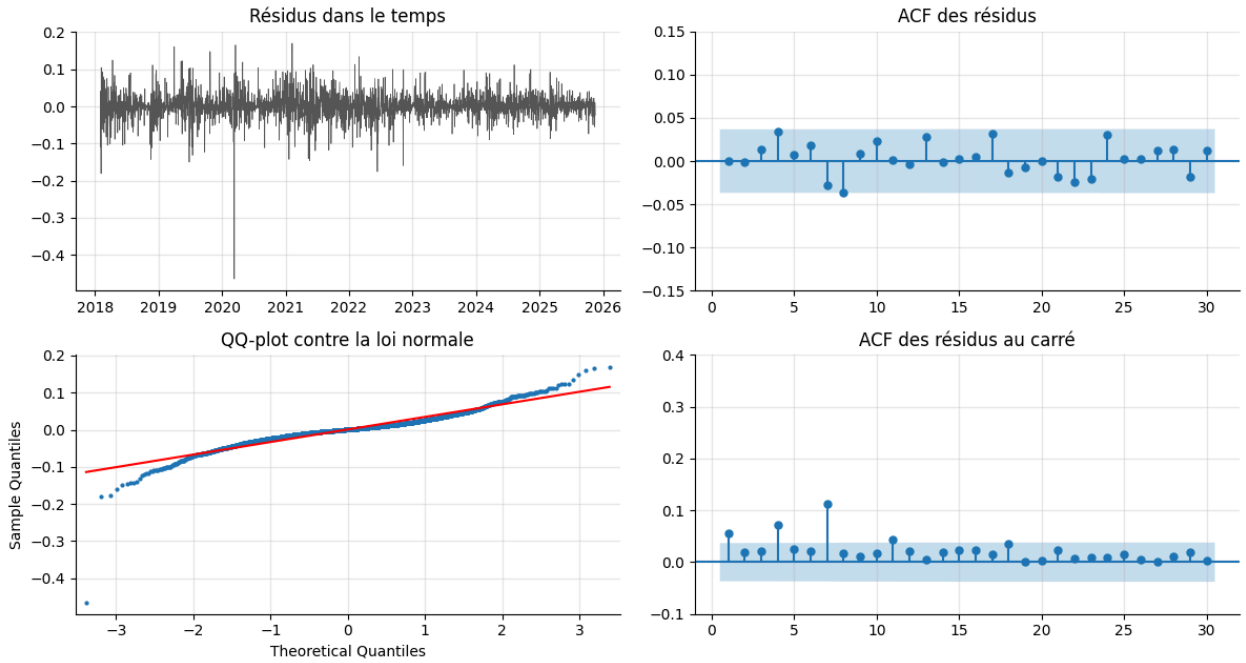


Figure 3 — Diagnostic des résidus de l'ARIMA(2,1,0)

4.2 VAR, Granger et cointégration

Le VAR est estimé sur les rendements car il demande des séries stationnaires. L'AIC choisit 4 retards (le BIC 0) ; on a pris p = 4 pour pouvoir tester la causalité. Le VAR est stable, mais le test portemanteau multivarié rejette l'absence d'autocorrélation (p = 0,01), donc le diagnostic n'est pas parfait.

Tableau 4 — Causalité de Granger et cointégration

Test	Résultat	Conclusion
Granger : ETH → BTC	p = 0,025	Significatif
Granger : BTC → ETH	p = 0,277	Non significatif
Johansen (trace, r = 0)	8,54 < 15,49	Pas de cointégration
Engle-Granger	p = 0,40	Pas de cointégration

Le passé de l'Ethereum aide à prévoir le Bitcoin au sens de Granger, mais l'effet est très faible : un choc sur l'ETH change le BTC de 0,15 % au maximum et l'effet disparaît en 5 jours. Il faut aussi rappeler que Granger est une causalité prédictive et pas une vraie cause. L'essentiel du lien entre les deux actifs se fait le même jour (corrélation des résidus de 0,83).

Il n'y a pas de cointégration : l'écart entre les deux log-prix dérive sans revenir vers une valeur d'équilibre (figure 4). On n'a donc pas estimé de VECM, et le VAR en différences reste le bon modèle. Les deux cryptos sont corrélées au jour le jour mais leur rapport de prix n'est pas stable à long terme.



Figure 4 — Écart à la relation de long terme entre log BTC et log ETH

4.3 GARCH

L'effet ARCH trouvé sur les résidus de l'ARIMA justifie un modèle de volatilité. On a comparé plusieurs modèles sur les rendements en %.

Tableau 5 — Comparaison des modèles de volatilité

Modèle	AIC	BIC	Persistance
GARCH(1,1) normale	14 690,1	14 713,9	0,954
GARCH(1,1) Student	13 998,1	14 027,9	1,000
GJR-GARCH(1,1) Student	14 000,0	14 035,7	1,000
EGARCH(1,1) Student	13 978,6	14 014,3	0,987

La loi de Student améliore beaucoup le modèle (692 points d'AIC), ce qui est logique avec les queues épaisses. On garde l'**EGARCH Student**, meilleur AIC et BIC. Ses paramètres : $\alpha = 0{,}19$ (réaction aux chocs), $\beta = 0{,}99$ (forte persistance, demi-vie d'environ 54 jours), et γ non significatif (pas d'effet de levier). Les GARCH d'ordre supérieur n'apportaient rien.

Après le GARCH, le test ARCH-LM sur les résidus standardisés donne $p = 0{,}87$ contre 3×10^{-8} avant : la variance conditionnelle est bien modélisée. Sur le test, l'EGARCH prévoit la variance un peu mieux que la variance glissante sur 30 jours (QLIKE 2,74 contre 2,81).

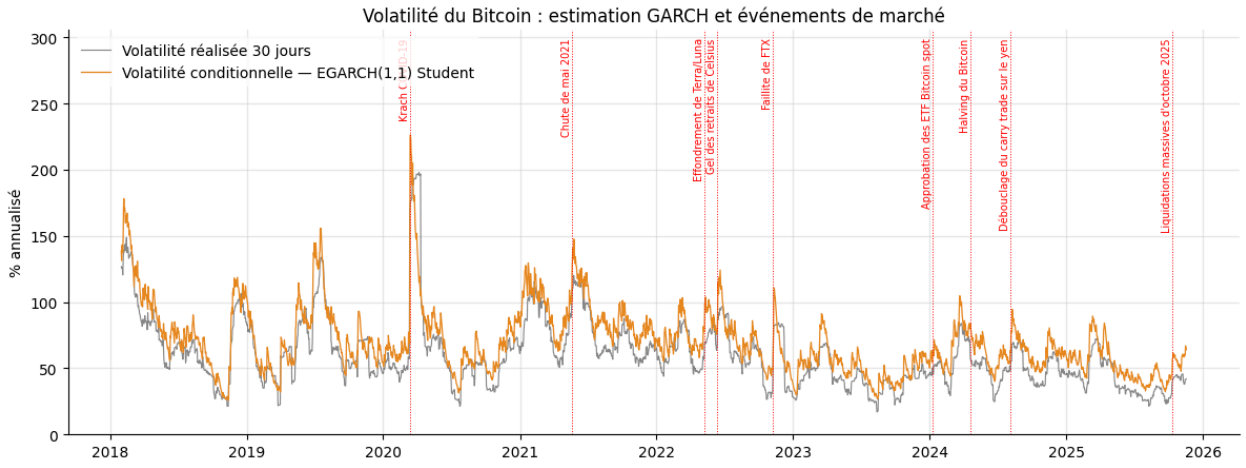


Figure 5 — Volatilité conditionnelle estimée par l'EGARCH et événements de marché

Les pics correspondent aux crises connues : COVID (226 % annualisé en mars 2020), mai 2021, Terra/Luna et FTX en 2022. Les événements annoncés à l'avance (halving, ETF Bitcoin) ne font presque pas monter la volatilité.

5. Modélisation avancée (Python)

On a entraîné un LSTM et un GRU. La cible est la suite des 10 prochains rendements et non le prix, car avec le prix le réseau recopie juste la dernière valeur. Les entrées sont les rendements du BTC et de l'ETH et la volatilité sur 30 jours, normalisés avec les statistiques de l'apprentissage. On a utilisé l'arrêt anticipé sur une validation chronologique.

Pour les hyperparamètres, on a testé 6 configurations (fenêtre de 10, 30 ou 60 jours, 16 à 64 unités, dropout 0 ou 0,2). Toutes donnent entre 0,9998 et 1,008 fois la perte de la prévision naïve, donc le choix change très peu de chose. On a gardé une couche de 32 unités, fenêtre 60, dropout 0,2.

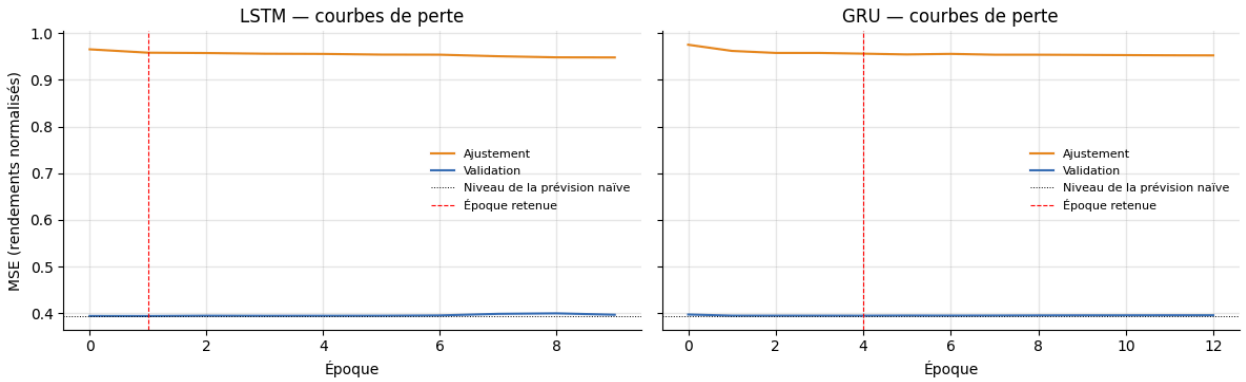


Figure 6 — Courbes de perte du LSTM et du GRU (pointillé : niveau de la prévision naïve)

La perte de validation reste au niveau du naïf et la meilleure époque arrive très tôt (2 pour le LSTM, 5 pour le GRU) : le réseau ne trouve pas de signal. La validation croisée walk-forward sur 4 périodes confirme ce résultat (rapport au naïf : 1,000 ± 0,004 pour le LSTM et 0,997 ± 0,002 pour le GRU).

On a aussi testé un modèle hybride ARIMA + LSTM, où le LSTM corrige les résidus de l'ARIMA. La correction est très petite et le modèle est le moins bon sur le test, ce qui est cohérent avec le Ljung-Box : il ne restait rien à prendre dans les résidus.

6. Prévision et évaluation

Tableau 6 — Erreurs sur le test (317 prévisions par horizon)

Modèle	RMSE 1 j ($)	MAPE 1 j	RMSE / naïf 1 j	RMSE / naïf 5 j	RMSE / naïf 10 j
Naïf	1 750	1,61 %	1,000	1,000	1,000
ARIMA(2,1,0)	1 753	1,61 %	1,001	0,999	1,000
VAR(4)	1 754	1,62 %	1,002	1,004	1,017
LSTM	1 752	1,61 %	1,001	1,005	1,016
GRU	1 751	1,61 %	1,001	1,001	1,011
Hybride	1 757	1,62 %	1,004	—	—

Tous les modèles ont presque la même erreur, environ 1 750 $ à un jour (1,6 % du prix), et aucun ne fait vraiment mieux que la prévision naïve. Les modèles plus complexes (VAR, LSTM, GRU) deviennent même un peu moins bons à 10 jours. Les tableaux MSE et MAE complets sont dans le notebook.

Pour savoir si les écarts sont réels, on a fait le test de Diebold-Mariano de chaque modèle contre le naïf : sur les 13 tests, la plus petite p-value est 0,34. **Aucune différence n'est significative.**

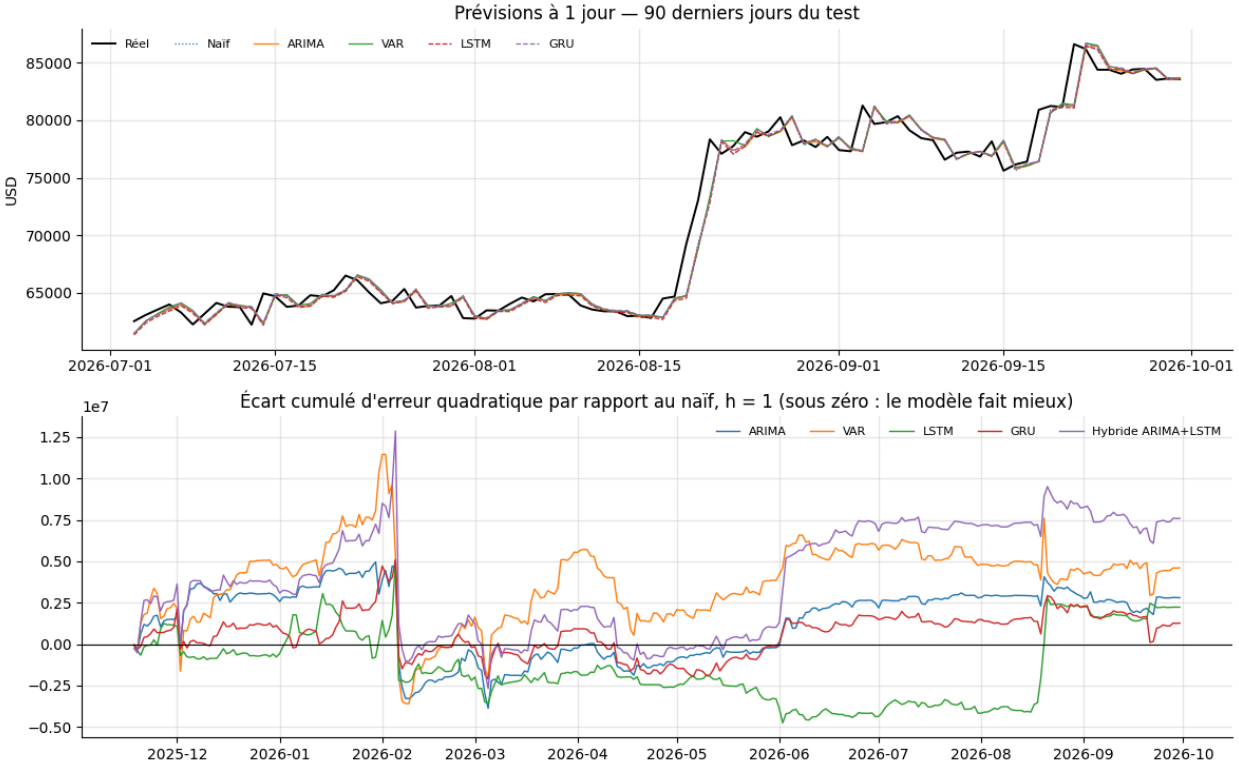


Figure 7 — Prévisions à 1 jour (haut) et écart cumulé d'erreur par rapport au naïf (bas)

Sur la figure 7, toutes les prévisions suivent le prix avec un jour de retard, comme le naïf. Les écarts entre modèles viennent surtout de quelques jours extrêmes, comme le 5 février 2026 (−15 %). La prévision à 10 jours de l'ARIMA est presque plate, avec un intervalle à 95 % très large (de 74 760 à 113 326 $). Sur tout le test, cet intervalle contient le vrai prix dans 98,4 % des cas, donc il est trop large, car le test a été plus calme que l'apprentissage (volatilité de 45 % contre 66 %).

Tableau 7 — Comparaison des modèles

Modèle	Paramètres	Temps	Intervalles	Interprétabilité
Naïf	0	0 s	Non	Totale
ARIMA(2,1,0)	3	0,5 s	Oui	Bonne
VAR(4)	18	< 0,1 s	Oui	Bonne (Granger, IRF)
LSTM	4 938	15 s	Non	Faible
GRU	3 882	25 s	Non	Faible
EGARCH (volatilité)	6	0,2 s	Sur la variance	Bonne

Pour prévoir le prix, le meilleur choix reste la prévision naïve : aucun modèle ne la bat et elle ne coûte rien. Si on veut un modèle statistique, l'ARIMA(2,1,0) donne le même résultat avec 3 paramètres et un intervalle de prévision, alors que le LSTM en a près de 5 000. Le seul modèle vraiment utile est l'EGARCH, pour prévoir le risque.

7. Extension : corrélation glissante (Python)

On a calculé la corrélation entre les rendements BTC et ETH sur une fenêtre de 90 jours. Elle n'est pas constante : elle va de 0,56 (janvier 2021) à 0,96 (janvier 2023), avec une moyenne de 0,84, et elle est plus forte sur le test (0,90) que sur l'apprentissage (0,83). Elle n'est pas liée à la volatilité (Spearman p = 0,67). Cette instabilité explique en partie pourquoi le VAR, qui suppose des coefficients constants, ne marche pas bien.

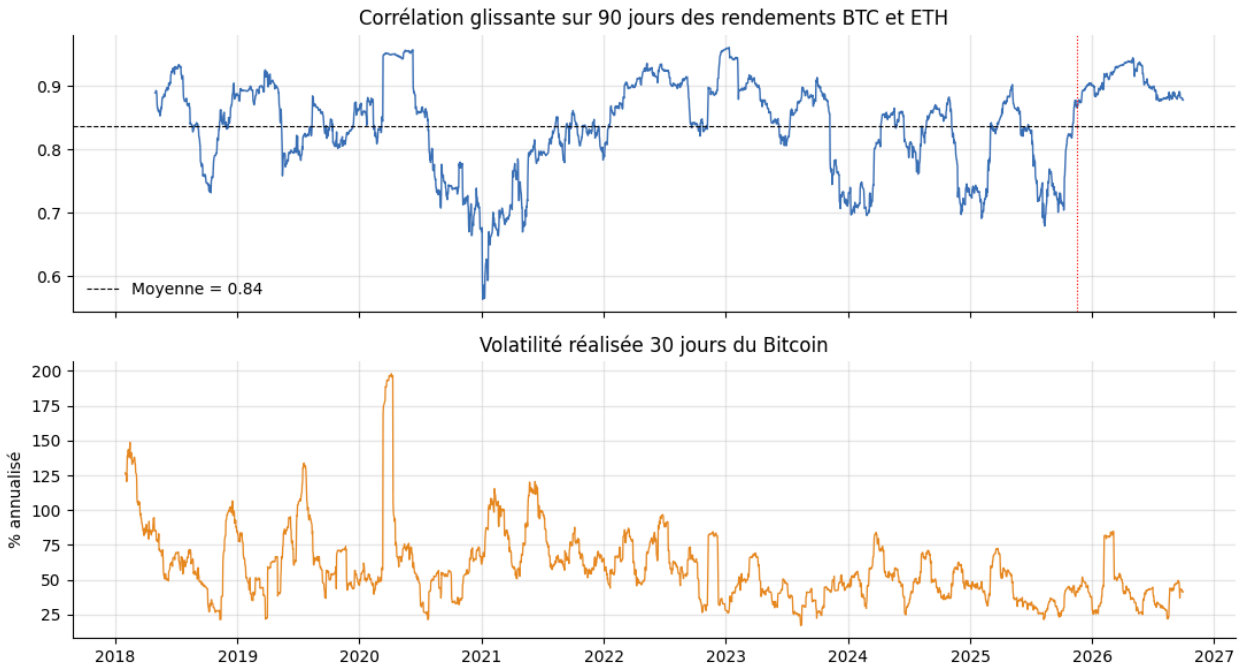


Figure 8 — Corrélation glissante sur 90 jours et volatilité réalisée du Bitcoin

8. Utilisation d'un LLM

Le notebook génère trois prompts avec nos vrais chiffres (annexe B) : un pour proposer des modèles à partir des statistiques descriptives, un pour expliquer les résultats à un non-spécialiste, et un pour faire des recommandations d'investissement simulées avec leurs limites. Chaque prompt demande au LLM de ne pas inventer de chiffres, pour pouvoir vérifier ses réponses.

Notre interprétation avant le LLM : séries I(1), ARIMA d'ordre faible, queues épaisses et effet ARCH, Granger ETH → BTC significatif mais sans intérêt pratique, pas de cointégration, aucun modèle ne bat le naïf, seule la volatilité est prévisible. Dans les réponses du LLM on vérifie surtout les chiffres inventés, la confusion entre Granger et vraie causalité, et les prévisions de hausse ou de baisse que nos résultats ne justifient pas.

Les trois prompts ont été soumis à **ChatGPT** (OpenAI) le 12 octobre 2026 ; ses réponses complètes sont en annexe C.

Prompt 1 — hypothèses de modèles

ChatGPT propose la même démarche que nous : différencier les log-prix (d = 1), tester des ARMA d'ordre faible, puis un test ARCH-LM et un GARCH à loi de Student, avec EGARCH ou GJR en extension. Il note bien qu'un skewness négatif ne prouve pas un effet de levier, ce que nos résultats confirment (γ non significatif), et qu'une corrélation de 0,83 ne prouve ni causalité ni cointégration. Il n'invente aucun chiffre. Par contre la corrélation est mal affichée dans son tableau (un code LaTeX apparaît à la place du chiffre), il parle de « log-prix stationnaires » juste après avoir dit le contraire, il conseille une constante que nos critères n'ont pas retenue, et surtout il ne propose pas de tester la cointégration alors que les deux log-prix sont I(1).

Prompt 2 — explication pour un décideur

La synthèse est fidèle : le naïf fait aussi bien que les autres modèles, aucune différence n'est significative, Granger n'est pas une vraie causalité et l'absence de cointégration est présentée correctement. Les chiffres sont tous exacts. Le problème est la hiérarchie des messages : le titre « Ethereum pourrait apporter une information utile » donne une impression positive alors que le VAR ne fait pas mieux que le naïf, et le résultat le plus utile (la volatilité est prévisible, effet ARCH éliminé avec p = 0,87) est réduit à « décrit correctement certains aspects ». Il ne dit pas non plus que les variations extrêmes sont fréquentes (kurtosis de 18), ce qui est pourtant important pour un décideur.

Prompt 3 — recommandations simulées

ChatGPT ne recommande ni achat ni vente à partir de la prévision, ses calculs sont justes (amplitude de 41,9 % du prix, gain de 0,03 % sur le naïf) et il donne lui-même beaucoup de limites (changements de régime, événements extrêmes, risques réglementaires et de conservation). Mais ses allocations (5 %, 20 % et 60 % de crypto) ne viennent pas des résultats : la même volatilité de 66 % sert à justifier 5 % pour le profil prudent et 60 % pour le profil dynamique. Il place aussi jusqu'à 20 % en Ethereum sans aucune donnée sur l'ETH. Surtout, il ne se sert pas du seul résultat exploitable : puisque la volatilité est prévisible, il aurait fallu proposer d'ajuster l'exposition selon la volatilité prévue. Nous ajoutons comme limites que le test a été plus calme que l'apprentissage (45 % contre 66 % de volatilité), que les données journalières cachent les mouvements dans la journée et qu'aucun frais n'est pris en compte.

Bilan

ChatGPT n'a inventé aucun chiffre, grâce aux prompts qui l'interdisaient. Ses erreurs sont d'un autre type : un oubli de méthode (la cointégration), une mauvaise mise en avant des résultats et

des chiffres présentés comme justifiés alors qu'ils sont arbitraires (les allocations). Il est utile pour structurer et vulgariser, mais tout doit être vérifié avec nos résultats.

Nous avons aussi utilisé un assistant LLM pendant le projet, surtout pour structurer le code et comprendre certaines méthodes (cointégration, ADF/KPSS, walk-forward). Cela nous a fait gagner du temps. Par contre il ne pouvait pas exécuter le code ni connaître nos résultats : il y a eu une erreur dans le code à la première exécution, et certaines de ses attentes étaient fausses (il pensait que le Bitcoin menait l'Ethereum, nos données montrent l'inverse au sens de Granger). Tous les résultats viennent de notre exécution.

9. Discussion critique

Limites des modèles

- Hypothèses violées : les résidus ne sont pas normaux et la variance n'est pas constante pour l'ARIMA et le VAR, donc leurs intervalles de prévision ne sont pas fiables (98,4 % de couverture au lieu de 95 %).
- Le VAR garde un peu d'autocorrélation dans ses résidus (portemanteau $p = 0{,}01$).
- Instabilité : la volatilité et la corrélation BTC/ETH changent dans le temps, alors que les modèles supposent des paramètres constants. L'AIC et le BIC ne choisissent pas le même modèle, ce qui montre que le signal est très faible.
- Échantillon : un seul test de 317 jours, plus calme que l'apprentissage, et des résultats qui dépendent de quelques jours extrêmes. Pour les réseaux de neurones, environ 2 500 exemples c'est peu.
- Données : on n'utilise que les prix journaliers ; pas de données horaires, de volume ou d'actualités.

IA générative et séries temporelles financières

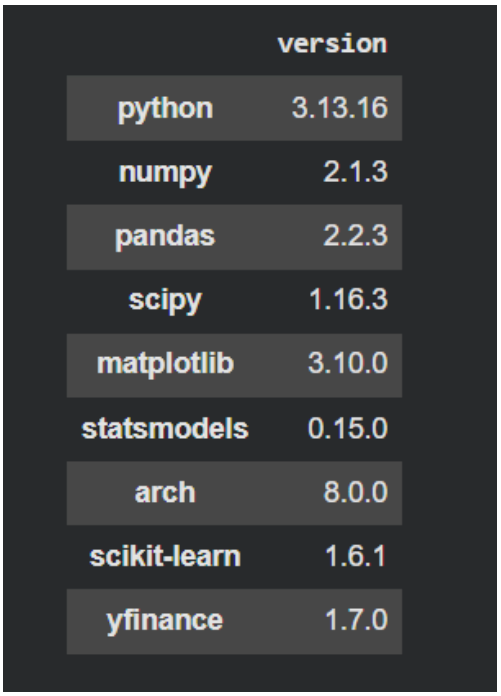
Un LLM aide beaucoup pour écrire du code, rappeler les bonnes pratiques (pas de k-fold, pas de fuite de données) et expliquer les résultats simplement. Mais il ne calcule pas : il peut inventer des p-values ou des coefficients, confondre corrélation, Granger et causalité, et il a tendance à raconter une histoire même quand les données disent qu'il n'y a rien à prévoir. En finance, une erreur peut mener à une mauvaise décision, donc tout ce qu'il produit doit être vérifié par l'exécution et les tests. Pour nous c'est un bon assistant, pas une source de résultats.

10. Conclusion

La réponse à notre question est non : le prix du Bitcoin ne se prévoit pas mieux que par la prévision naïve à 1, 5 ou 10 jours, et l'Ethereum n'aide pas. Le prix se comporte comme une marche aléatoire, ce qui est cohérent avec l'idée d'un marché efficient. Ce qu'on peut prévoir, c'est la volatilité, avec l'EGARCH. Ce projet montre aussi qu'un modèle plus complexe n'est pas forcément meilleur et qu'il faut toujours comparer à une référence simple avec un test statistique. Pour aller plus loin, on pourrait tester un ARIMA-GARCH pour avoir de meilleurs intervalles, ou un DCC-GARCH pour la corrélation.

Annexe A — Environnement

Fichiers : projet_btc_eth.ipynb, projet_btc_eth.Rmd.



	version
python	3.13.16
numpy	2.1.3
pandas	2.2.3
scipy	1.16.3
matplotlib	3.10.0
statsmodels	0.15.0
arch	8.0.0
scikit-learn	1.6.1
yfinance	1.7.0

Figure 9 — Bibliothèques et version utilisées

Annexe B — Prompts

PROMPT 1

```
============================== PROMPT 1 ==============================
Tu es un économètre spécialiste des séries temporelles financières.
Voici les statistiques descriptives de deux séries journalières (2848 observations, du 2018-01-31 au 2025-11-17) : le Bitcoin (BTC-USD) et l'Ethereum (ETH-USD).

Rendements logarithmiques journaliers du Bitcoin : moyenne = 0.00078, écart-type = 0.03393, minimum = -0.4647, maximum = 0.1718, skewness = -0.954, kurtosis en excès = 15.26.
Rendements logarithmiques journaliers de l'Ethereum : moyenne = 0.00036, écart-type = 0.04468, skewness = -0.888, kurtosis en excès = 11.42.
Corrélation entre les deux rendements : 0.830.

Tests de stationnarité :
- log-prix BTC : ADF p = 0.5292, KPSS p = 0.0100
- rendements BTC : ADF p = 0.0000, KPSS p = 0.1000
- log-prix ETH : ADF p = 0.4076, KPSS p = 0.0100
- rendements ETH : ADF p = 0.0000, KPSS p = 0.1000
(La p-value du KPSS est bornée entre 0,01 et 0,10 par le logiciel.)

Autocorrélation des rendements BTC au retard 1 : -0.0517. Nombre de retards significatifs parmi les 20 premiers : 2 pour les rendements, 4 pour les rendements au carré.
Force de la saisonnalité hebdomadaire (décomposition STL) : 0.000.

À partir de ces seules informations :
1. Propose les hypothèses de modèles à tester (famille de modèle, ordres plausibles, transformations), en justifiant chaque hypothèse par une statistique précise ci-dessus.
2. Indique pour chaque hypothèse le test statistique qui permettrait de la valider ou de la rejeter.
3. Signale explicitement ce que ces statistiques ne permettent PAS de conclure.
N'invente aucun chiffre qui ne figure pas ci-dessus.
```

Figure 10 — Prompt 1

PROMPT 2

```
============================== PROMPT 2 ==============================
Voici les résultats d'une étude de prévision du prix du Bitcoin, évaluée sur 317 jours (2025-11-18 au 2026-09-30).

Erreurs de prévision à 1 jour :
- Naïf : RMSE = 1,750 USD, MAPE = 1.61 %, RMSE relatif au naïf = 1.0000
- ARIMA : RMSE = 1,753 USD, MAPE = 1.61 %, RMSE relatif au naïf = 1.0014
- VAR : RMSE = 1,754 USD, MAPE = 1.62 %, RMSE relatif au naïf = 1.0024
- LSTM : RMSE = 1,752 USD, MAPE = 1.61 %, RMSE relatif au naïf = 1.0011
- GRU : RMSE = 1,751 USD, MAPE = 1.61 %, RMSE relatif au naïf = 1.0007
- Hybride ARIMA+LSTM : RMSE = 1,757 USD, MAPE = 1.62 %, RMSE relatif au naïf = 1.0039

Test de Diebold-Mariano (hypothèse nulle : même précision que la prévision naïve) :
- ARIMA contre naïf : statistique = 0.31, p = 0.7531
- VAR contre naïf : statistique = 0.33, p = 0.7426
- LSTM contre naïf : statistique = 0.21, p = 0.8315
- GRU contre naïf : statistique = 0.15, p = 0.8829
- Hybride ARIMA+LSTM contre naïf : statistique = 0.49, p = 0.6235

Modèle ARIMA retenu : ARIMA(2, 1, 0) sans dérive. Diagnostic des résidus : Ljung-Box p = 0.1277, Jarque-Bera p = 0.0000, kurtosis = 18.4, ARCH-LM p = 0.0000.
Causalité de Granger (VAR d'ordre 4 sur les rendements) : « ETH ne cause pas BTC » p = 0.0249 ; « BTC ne cause pas ETH » p = 0.2771.
Cointégration des log-prix : test de Johansen, statistique de la trace pour r = 0 : 8.54 (valeur critique à 5 % : 15.49) ; Engle-Granger p = 0.4053.
Volatilité : modèle EGARCH(1,1) Student, persistance = 0.9872, demi-vie d'un choc = 54 jours. ARCH-LM sur les résidus standardisés : p = 0.8706.

Explique ces résultats à un décideur qui n'a aucune formation en statistique, en une page maximum :
1. Ce que l'étude a cherché à faire.
2. Ce que les résultats disent, en langage courant, sans jargon.
3. Ce que le décideur peut et ne peut pas en tirer.
N'invente aucun chiffre et ne tire aucune conclusion que les résultats ci-dessus ne soutiennent pas.
```

Figure 11 — Prompt 2

PROMPT 3

```
============================== PROMPT 3 ==============================
Contexte : exercice académique. Les recommandations demandées sont SIMULÉES et ne constituent pas un conseil financier.

Un modèle ARIMA(2, 1, 0) estimé sur le prix du Bitcoin jusqu'au 2025-11-17 (dernier prix connu : 92,094 USD) donne, à 10 jours :
prévision = 92,044 USD, intervalle de prévision à 95 % = [74,760 ; 113,326] USD.
Sur 317 jours de test, l'erreur de ce modèle à 10 jours est : RMSE = 5,985 USD, MAPE = 5.69 %, soit 0.9997 fois l'erreur de la prévision naïve (« le prix ne bouge pas »).
La couverture réelle de son intervalle à 95 % à 1 jour est de 98.4 %.
La volatilité annualisée médiane estimée par le modèle EGARCH(1,1) Student est de 66 %, avec un maximum de 226 %.
La corrélation des rendements Bitcoin/Ethereum est de 0.83 en moyenne et a varié entre 0.56 et 0.96 sur des fenêtres de 90 jours.

1. Formule des recommandations d'investissement simulées pour trois profils : prudent, équilibré, dynamique.
2. Pour chaque recommandation, cite le résultat chiffré sur lequel elle s'appuie.
3. Formule toi-même, de façon explicite et détaillée, les limites et les risques de ces recommandations : limites statistiques des modèles, risques propres au marché des cryptomonnaies, et
ce que les chiffres ci-dessus ne permettent pas d'affirmer.
```

Figure 12 — Prompt 3

Annexe C — Résultats en R

D.1. Modèle auto.arima:

modele	k	AIC	BIC
ARIMA(0,1,0)	0	-11182.99	-11177.03
ARIMA(1,1,0)	1	-11188.35	-11176.45
ARIMA(0,1,1)	1	-11187.72	-11175.81
ARIMA(1,1,1)	2	-11191.15	-11173.29

```
# Lance auto.arima en recherche exhaustive : confirme ou contredit l'identification manuelle par un critère objectif.
auto <- auto.arima(y_train, d = 1, seasonal = FALSE, max.p = 3, max.q = 3, stepwise = FALSE, approximation = FALSE, ic = "ai
c", allowdrift = TRUE)
auto_bic <- auto.arima(y_train, d = 1, seasonal = FALSE, max.p = 3, max.q = 3, stepwise = FALSE, approximation = FALSE, ic =
"bic", allowdrift = TRUE)
cat("auto.arima selon l'AIC :", capture.output(print(auto))[2], "\n")
```

```
## auto.arima selon l'AIC : ARIMA(2,1,1)
```

```
cat("auto.arima selon le BIC :", capture.output(print(auto_bic))[2], "\n")
```

```
## auto.arima selon le BIC : ARIMA(0,1,0)
```

```
cat(sprintf("Écart d'AIC entre le meilleur candidat manuel et auto.arima : %.2f\n", min(manuel$AIC) - auto$aic))
```

```
## Écart d'AIC entre le meilleur candidat manuel et auto.arima : 1.17
```

Figure 13 — Sélection du modèle ARIMA

Interprétation : Le modèle ARIMA(2,1,1), sélectionné selon le critère AIC, est retenu pour la prévision du prix du Bitcoin. Les résultats montrent que le modèle s'ajuste correctement aux données d'entraînement. Cependant, les performances sur les données de test indiquent que ses prévisions restent très proches de celles du modèle naïf. Ainsi, ARIMA apporte une amélioration limitée de la précision des prévisions.

D.2. Test de cointégration de Johansen:

```
tableau(tab_jo, "03_johansen", 3)
```

H0	statistique	critique_10pct	critique_5pct	critique_1pct	decision
r <= 1	1.390	6.50	8.18	11.65	H0 non rejetée
r = 0	8.536	15.66	17.95	23.52	H0 non rejetée

Figure 14 —Résultats du test de cointégration de Johansen

Interprétation : Le test de Johansen ne permet pas de rejeter l'hypothèse d'absence de cointégration au seuil de 5 %. Le rang de cointégration estimé est donc nul ($r = 0$). Cela signifie qu'aucune relation d'équilibre de long terme entre les prix du Bitcoin et de l'Ethereum n'est mise en évidence par ce test. Par conséquent, l'utilisation d'un modèle VECM n'est pas justifiée par ces résultats.

D.3. Modèle GARCH retenu:

```
tableau(tab_garch, "03_garch_comparaison")
```

	modele	k	logL	AIC	BIC	persistance	LB_z2_10_p	ARCH_LM_z_10_p
Chi-squared	GARCH(1,1) normale	4	-7346.410	14700.82	14724.64	0.9539	0.8186	0.8422
Chi-squared1	GARCH(1,1) Student	5	-6998.627	14007.25	14037.03	0.9990	0.8855	0.9020
Chi-squared2	GARCH(2,1) Student	6	-6998.439	14008.88	14044.60	0.9990	0.8871	0.9020
Chi-squared3	GJR-GARCH(1,1) Student	6	-6998.447	14008.89	14044.62	0.9990	0.8809	0.8973
Chi-squared4	EGARCH(1,1) Student	6	-6987.710	13987.42	14023.15	0.9862	0.8922	0.9039

Figure 15 —Estimation du modèle GARCH retenu

Interprétation : Le modèle EGARCH(1,1) avec une distribution de Student est retenu car il présente le BIC le plus faible parmi les modèles comparés. La persistance de la volatilité est élevée (0,9862), ce qui indique que les variations importantes du marché peuvent avoir des effets qui durent dans le temps. De plus, le test ARCH-LM après estimation donne une p-value de 0,9039, ce qui ne met pas en évidence d'effet ARCH résiduel significatif. Le modèle semble donc bien prendre en compte l'hétéroscédasticité conditionnelle des rendements.

D.4. Métriques de prévision:

```
tableau(tab_m, "06_metriques", 4)
```

horizon	modele	n	MSE	RMSE	MAE	MAPE_pct	RMSE_relatif_naif
1	Naïf	317	3063521	1750.292	1196.180	1.6052	1.0000
1	ARIMA	317	3072585	1752.879	1202.317	1.6116	1.0015
1	VAR	317	3078056	1754.439	1212.483	1.6234	1.0024
5	Naïf	317	15381181	3921.885	2779.915	3.7011	1.0000
5	ARIMA	317	15250004	3905.125	2776.996	3.6966	0.9957
5	VAR	317	15491607	3935.938	2809.913	3.7457	1.0036
10	Naïf	317	35841897	5986.810	4242.114	5.6946	1.0000
10	ARIMA	317	35696263	5974.635	4238.660	5.6924	0.9980
10	VAR	317	37061126	6087.785	4296.561	5.7858	1.0169

Figure 16 —Comparaison des performances de prévision

Interprétation : Les résultats montrent que l'erreur de prévision augmente globalement avec l'horizon, passant d'un RMSE d'environ 1 753 pour un jour à près de 5 975 pour dix jours avec ARIMA. ARIMA obtient les meilleurs résultats numériques aux horizons de 5 et 10 jours, mais l'amélioration par rapport au modèle naïf reste faible. Le modèle VAR ne surpasse pas systématiquement le modèle naïf. Ces résultats montrent que la prévision des prix des cryptomonnaies reste difficile, notamment à cause de leur forte volatilité.